

FAG 确定性计算 – Band 多 Batch 场景

范杰于斌

2026 年 8 月 11 日

1 多 batch 情形

GQA 设定每 N_1 个 batch 有额外的列的轮次约束，可以将它们分成 b 组。处理大致分成两步，完整的 batch，剩余的 batch。仍然注意我们 batch 的 id 的顺序，第 $1 - N_1$ 个 batch 对应 $b = 1$ ，它们之间有约束，第 $(N_1 + 1) - 2N_1$ 个 batch 对应 $b = 2$ ，它们有约束，依此类推。

在完整 batch 的处理中，只需要注意到一个 batch 的最大轮次是

$$mn - \frac{(m - p + 1)(m - p)}{2} - \frac{(n - q + 1)(n - q)}{2},$$

这里的 m, n 是裁剪后有效的 m, n 。其余的处理方式和 Causal 处理的方式完全相同。

此时剩余 $b_2 = b - b_1 k$ 组 batch。在保证 $b_2 > 0$ 的基础上，仍然分成 $p + q > m$ 和 $p + q \leq m$ 两大类情况讨论。

先看 $p + q > m$ 的情况，首先处理对称性好的情况，比如 $2b_2 = k$ 且 $L_1 = L_3$ ，这里与多 batch 的 band 场景不同的地方就是根据 N_1 参数做一些额外的坐标变换。由于此时 batch 的最长列已经是 m ，拼接简单，根据 $p + q$ 与 n 的大小关系简单讨论即可。

而 $p + q \leq m$ 的情况这样操作并不是总是好的，虽然利用 TND-Band 的拼接思路可以有效转化为 Dense 处理，但是这样会额外增加列的约束，比如原来只是 $(p + q - 1)N_1$ 的轮次约束增加到了 mN_1 ，对于某些 m, n 与 p, q 数值差距大的情况效果会很差。 $n \leq m$ 的情况可以对整行进行移动，拼接近似得到一个 $(p + q - 1) \times n$ 的矩形。这样会避免上面提到的轮次约束增加的问题。而 $n > m$ 的情况要通过轮次计算来帮助判断选择是否拼接，第一种轮次是 $(p + q - 1) \max(\lceil \frac{b_2 n N_1}{k} \rceil, \lceil \frac{n}{p + q - 1} \rceil, N_1)$ ，第二种轮次是 $m \times \max(\lceil \frac{b_2(p + q - 1)N_1}{k} \rceil, \lceil \frac{p + q - 1}{m} \rceil, N_1)$ 。通过比较，如果第二种的轮次比较少，那么是拼成 $m \times (p + q - 1)$ 的矩形，调用 Dense 的情况就可以了。但如果是第一种的轮次比较少，那么无需拼接，将它看成一个 $(p + q - 1) \times n$ 的平行四边形，调用无需局部调整的 Dense 方案，每一列的第一个有效任务块的轮次虽然相同，但是平行四边形的结构使得轮次偏移，天然保证了轮次的不冲突。