

FAG 确定性计算-Causal 多 Batch 场景

范杰于斌

2026 年 8 月 11 日

1 多 batch 的情景

这里只处理 $m \geq n$ 的情况。

与 Dense 的 GQA 相同，每 N_1 个 batch 有额外的列的轮次约束，可以将它们分成 b 组。仍然是三步走，完整的 batch， tk 列的拼接，尾项的处理。

所有的操作都可以基于多 batch(G2k 版本) 简单修改，额外需要考虑的就是处理由于 N_1 的引入，batch 的 id 应该怎么变化。注意我们 batch 的 id 的顺序，第 $1 - N_1$ 个 batch 对应 $b = 1$ ，它们之间有约束，第 $(N_1 + 1) - 2N_1$ 个 batch 对应 $b = 2$ ，它们有约束，依此类推。

在第一部分的处理中，一个 batch 的最大轮次是 $size_tri = \frac{(2m - n + 1)n}{2}$ ，我们用参数 $size_tri_group$ 来记录它的 N_1 倍，即一组的任务块数目，对于轮次 r ，先模这个数得到相对轮次 a ，然后得到 $N1_id = \lceil \frac{a}{size_tri} \rceil$ ，此时真正的单 batch 内的相对轮次还要让它模 $size_tri$ 。计算 $b_id = k(\lceil \frac{r}{size_tri_group} \rceil - 1) + j$ ，最终的 batchID 就是 $(b_id - 1)N1 + N1_id$ 。需要列错核就微调一下。

第二部分的处理是仍然是 tk 列的部分两两拼接，但是是跨组拼接，对应次序拼，得到 $half$ 组，每组仍然是 N_1 个，这样便于调用 GQA-Dense 的函数。相应的利用映射还原坐标就可以。

剩余的部分逻辑类似，也需要 batchID 的映射。除此之外只有一点需要注意，见下图，拼接后分配轮次如果采用第一种方式，那么一个 batch 的轮次会间隔，第二种就会连续。如果知道了最大轮次，那么完全可以选择第二种方式， $N1_id = \lceil \frac{a}{rm} \rceil$ $a = a \bmod rm$ (or rm)，轮次就全分离开了。第一种方式的计算逻辑是 $N1_id = a \bmod N_1$ (or N_1)， $a = \lceil \frac{a}{N_1} \rceil$ ，这样是不需要最大轮次的信息的，我们在最后尾项的处理中使用了这一计算方式，实际上前两部分的处理也可以直接用这个思路，但可能效果不如第二种方式。

1		
2		
3	9	
4	10	
5	11	15
6	12	16
7	13	17
8	14	18

1		
10		
2	5	
11	14	
3	6	8
12	15	17
4	7	9
13	16	18